

Juan Manuel Ahumada Vázquez

AWS Solutions Architect / Senior DevOps Engineer

Disponible para remoto — US · LATAM · EU time zones

WEB juanahumada.com
MAIL juan.ahumada94@gmail.com
TEL +52 867 753 7160
IN linkedin.com/in/jahumada94
GH github.com/jmav94
LOC Nuevo Laredo, Tamps., MX

PERFIL 01

Ingeniero en Sistemas Computacionales con más de **10 años** de experiencia en TI, especializado en el diseño, despliegue y operación de arquitecturas cloud en AWS bajo los principios del **Well-Architected Framework**. Soy responsable de la infraestructura y el ciclo de vida completo de un fleet de aplicaciones empresariales en producción 24/7 para una empresa de transporte transfronterizo (150 empleados, 370 tractocamiones, 500 cajas), y de la infraestructura AWS de una cartera de clientes de consultoría. Mi práctica abarca arquitectura cloud, automatización DevOps, ingeniería de confiabilidad (SRE), seguridad y optimización de costos, con **8+ años de TypeScript / Node.js** y **6+ años de Terraform**, y se extiende a **sistemas LLM en producción**.

STACK TÉCNICO 02

CLOUD & INFRA	AWS · ECS / Fargate · RDS · S3 · Lambda · CloudFront · Route 53 · IAM · Secrets Manager · Organizations · Terraform (6+ años) · CloudFormation · CDK
CI/CD & OBSERVABILIDAD	Docker · GitHub Actions · workflows multi-repo · blue-green · self-hosted runners · CloudWatch · Datadog · Grafana · Sentry
LENGUAJES & FRAMEWORKS	TypeScript (8+ años) · Node.js (8+ años) · Next.js / React · Python · Go · Bash · Java / Spring Boot
DATOS	PostgreSQL · pgvector · MySQL · Drizzle ORM · DMS / CDC · esquema e indexación
AI & LLM	RAG · agentes con tool-calling · embeddings y reranking · evals / LLM-as-judge · Bedrock · Claude Code

EXPERIENCIA 03

RAJO Transportes · Senior DevOps Engineer & AWS Solutions Architect

Ene 2025 — Presente · Nuevo Laredo, MX

Responsable de la arquitectura cloud en AWS de un fleet de **6+ aplicaciones empresariales** en operación 24/7. Ciclo de vida end-to-end: arquitectura, IaC, CI/CD, seguridad, observabilidad, costos y confiabilidad en producción.

LOGROS PRINCIPALES

- **COSTOS** Opero entornos AWS con presupuestos mensuales de entre `$350` y `$3,400 USD`; bajé la cuenta principal de `$614` a `~$400/mes` (`−35%`) vía right-sizing, optimización de cómputo y lifecycle de almacenamiento.
- **RENDIMIENTO** Reduje el **costo por petición 71%** y la latencia mediana de `2.0 s` a `0.56 s`; reconstruí dos listados inutilizables de `19.5 s → 6 ms` y `31.8 s → 13 ms`, y llevé el primer dato en red móvil lenta de `~21 s` a `5.0 s`.
- **CONFIABILIDAD** CI/CD multi-repo en 5 sistemas con **despliegues sin downtime y rollback automatizado**; **sincronización offline-first** para operación de campo crítica bajo conectividad intermitente; `49` alarmas de CloudWatch con runbooks de triage por categoría.
- **SEGURIDAD** Cerré un endpoint sin autenticación que exponía `47,651` registros (`~4,000` liquidaciones de nómina con nombre y salario) y una falla de autorización en `17+` rutas que permitía a un operador actuar a nombre de otro; remedié una exposición de datos personales en el asistente. IAM de mínimo privilegio, cifrado end-to-end y migración de acceso directo a la base de producción hacia un modelo **staging-readonly**.

- **TYPESCRIPT / NODE.JS** Construyo **TMS RJ** junto con el equipo de RJ: plataforma de transporte propia (Next.js, React, Drizzle ORM, PostgreSQL) con `3` apps complementarias en producción 24/7 y un **portal de permisionarios multi-tenant** servido desde el mismo deployment vía ruteo por host.
- **PLATAFORMA AI / LLM** Construí el **asistente RAG en producción** del TMS: pgvector con embeddings de OpenAI, reranking, agente con tool-calling y text-to-SQL, **compuerta de fidelidad** que bloquea respuestas sin sustento y recuperación que respeta los permisos de quien pregunta. Reorientar las preguntas frecuentes hacia métricas deterministas subió el acierto `5 puntos` y redujo el mal ruteo `79%`, con un **harness de evals con LLM-as-judge** corriendo en CI contra producción.

Wake Code · Solutions Architect & DevOps Lead

2018 — Presente

Infraestructura AWS y productos SaaS para una cartera de **5+ clientes en múltiples industrias** (SaaS móvil de consumo, punto de venta multi-sucursal, e-commerce, logística, bienes raíces, fitness). Responsabilidad end-to-end: arquitectura, IaC, CI/CD, rendimiento de base de datos, respuesta a incidentes, observabilidad y costos, con reportes trimestrales a dueños de negocio.

LOGROS PRINCIPALES

- **COSTOS A ESCALA** Llevé un entorno AWS multi-cuenta con Organizations (SaaS móvil de consumo, `~3,000` usuarios, dos regiones) de `$3,492` a `~$850/mes` — una reducción del `76%` sostenida tres trimestres consecutivos, con `~$982/mes` de ahorro permanente.
- **MIGRACIÓN EOL** Eliminé un **cargo de fin de soporte de** `~$33,000/año` actualizando `18` instancias RDS MySQL a 8.4 en cuatro olas ordenadas por criticidad — snapshot por ola, ventanas de `3–9 minutos` y validación de datos post-migración — llegando a `$0` en el mismo trimestre sin bajar de `99.95%` de disponibilidad.
- **CAUSA RAÍZ** Rastreé `~66,000` errores diarios que venían desde 2022 hasta un bucle recursivo de access logging en S3 que había acumulado `463M` objetos, y lo comprobé con un experimento controlado en un solo bucket antes de proponer el arreglo.
- **MIGRACIÓN A ECS** Migré 3 microservicios en producción (Java/Spring Boot) y 4 procesos batch desde VPS heredados a ECS Fargate con despliegues **blue-green sin downtime**; reducción de `~30%` (`~$794/mes`) vía right-sizing de cómputo, tuning de IOPS en RDS y lifecycle policies.
- **RENDIMIENTO DE BD** Resolví un deadlock crítico en producción sobre una tabla de `4.2M+ filas` con un índice compuesto (full scan `4.2M → 34 filas`); `85%` de reducción en fugas de conexiones (`137/h → 21/h`) vía tuning del pool en 55 servicios; pipeline de **AWS DMS** con `22 tablas` en CDC diario; RCA de una caída de `7h` por agotamiento del connection pool.
- **LEGADO A ESTÁTICO** Convertí el sitio PHP de un campus universitario público a un deployment estático en AWS, con fidelidad verificada ruta por ruta en `241` rutas internas.

TecNM Campus Nuevo Laredo · Docente

2019 — Presente · Nuevo Laredo, MX

- Imparto programación avanzada a nivel licenciatura en Ingeniería en Sistemas Computacionales, y asesoro a estudiantes en proyectos de residencia profesional y desarrollo de software.

EDUCACIÓN 04

2013 — 2018

TecNM Campus Nuevo Laredo

Ing. en Sistemas Computacionales

Mención honorífica por proyecto de residencia profesional; representé al Tecnológico Nacional de México campus Nuevo Laredo en concurso nacional de innovación tecnológica.

CERTIFICACIONES 05

AWS Certified Solutions Architect — Associate `SAA-C03 · en preparación`

Examen objetivo 2027.

IDIOMAS 06

Español	Nativo
Inglés	Profesional